

Documento de Requisitos

1. Visão Geral do Produto

1.1 Contexto

Universidades, grupos de pesquisa e gestores acadêmicos precisam consultar informações sobre pesquisadores, produções científicas, áreas de atuação e competências institucionais. Essas informações normalmente estão distribuídas em currículos Lattes, bases externas e documentos em formatos heterogêneos, o que dificulta a busca, a análise e a tomada de decisão.

O Currículo Lattes é uma fonte rica de dados acadêmicos, mas seus arquivos em XML precisam passar por um processo de extração, transformação e carga para se tornarem úteis em consultas estruturadas, buscas textuais, buscas semânticas e painéis analíticos.

1.2 Objetivo

Desenvolver um sistema de busca de informações de pesquisadores baseado em Full-Text Search e LLM, integrando Ciência de Dados, Inteligência Artificial Generativa, banco de dados relacional, banco vetorial, API REST, interface web e visualização analítica.

O sistema permitirá que usuários pesquisem pesquisadores e produções científicas por termos textuais e por similaridade semântica, com resultados organizados em uma interface web. Também gerará arquivos CSV para análises em Power BI.

2. Requisitos

2.1 Requisitos Funcionais - forma simplificada

RF-01 — Carregar Dados via ETL

Como administrador do sistema, quero importar arquivos XML do Currículo Lattes para o banco relacional, para disponibilizar dados estruturados dos pesquisadores.

Critérios de aceitação:

- Dado um XML válido do Lattes, quando o pipeline for executado, então os dados do pesquisador devem ser gravados no banco PostgreSQL.
- O sistema deve registrar as produções científicas associadas ao pesquisador.
- O processo deve evitar duplicidade básica de pesquisadores e produções.
- O pipeline deve ser executável via Apache Hop com interface gráfica

RF-02 — Buscar Produções por Texto

Como usuário, quero buscar produções científicas por termos textuais, para encontrar trabalhos relacionados ao tema pesquisado.

Critérios de aceitação:

- A busca deve considerar o título e palavras-chave das produções.
- O resultado deve listar título, ano, pesquisador e tipo de produção.

- A busca deve usar o recurso Full-Text Search nativo do PostgreSQL.
- O usuário deve conseguir combinar busca textual com filtros básicos (ano, tipo).

RF-03 — Buscar Produções Semanticamente

Como usuário, quero realizar busca semântica nos títulos das produções, para encontrar resultados relacionados ao sentido da consulta, mesmo sem correspondência exata de termos.

Critérios de aceitação:

- O sistema deve gerar embeddings para os títulos das produções via LangChain.
- Os vetores devem ser armazenados no PostgreSQL com a extensão pgvector.
- A API deve retornar resultados ordenados por similaridade (distância cosseno).

RF-04 — Consultar Perfil do Pesquisador

Como usuário, quero visualizar o perfil de um pesquisador e suas produções, para entender suas áreas de atuação e histórico acadêmico.

Critérios de aceitação:

- A tela deve exibir nome, identificador Lattes, áreas de atuação e lista de produções.
- A lista de produções deve permitir filtragem por ano ou tipo.
- A API deve ter endpoint dedicado para listar produções de um pesquisador específico.

RF-05 — Gerar Dados Analíticos em CSV

Como usuário, quero gerar CSVs analíticos com dimensões e fatos de produção científica, para construir painéis no Power BI.

Critérios de aceitação:

- O back-end deve gerar a dimensão de pesquisador (id, nome, área).
- O back-end deve gerar a dimensão de tempo (ano, quadriênio).
- O back-end deve gerar o fato de produção científica (pesquisador, tipo, ano, título).

Talvez criar mais requisitos funcionais (ou não)

2.2 Requisitos não funcionais

ID	Categoria	Descrição
RN F-0 1	Desempenho	Busca textual deve retornar resultados em até 2 segundos para base com 10.000 produções
RN F-0 2	Desempenho	Busca semântica deve retornar resultados em até 5 segundos para até 1.000 embeddings
RN F-0 3	Portabilidade	A solução deve rodar em ambiente Docker para garantir consistência entre ambientes
RN F-0 4	Manutenibilidade	O código deve seguir boas práticas (PEP 8 para Python) e estar versionado no Git


RN F-0 5	Usabilidade	A interface web deve ser responsiva e funcionar nos navegadores Chrome e Firefox
RN F-0 6	Interoperabilidade	A API REST deve responder em JSON e seguir os padrões HTTP (status codes, verbos)
RN F-0 7	Rastreabilidade	Todos os artefatos devem estar registrados no repositório Git com histórico de commits

3. Diagrama de Caso de Uso

3.1 Diagrama de Atores e Casos de Uso

Os atores primários do sistema são: Administrador (responsável pelo ETL), Usuário (pesquisador, aluno, professor). Os casos de uso principais são:

- UC-01: Executar Pipeline ETL (Administrador)
- UC-02: Buscar Produções por Texto (Usuário)
- UC-03: Buscar Produções Semanticamente (Usuário)
- UC-04: Visualizar Perfil do Pesquisador (Usuário)



4. Projeto arquitetural

5. Protótipo de média fidelidade

6. Esquema do banco